

```
1 from google.colab import drive
2 import pandas as pd
3 import json
4
5
6 # 구글 드라이브 마운트
7 drive.mount('/content/drive')
```

Mounted at /content/drive

```
1 SAVE_PATH='/content/drive/MyDrive/프로젝트/2025_과외_프로젝트1/data'
```

```
1 data1 = pd.read_pickle(SAVE_PATH+'음성데이터전처리_1.pkl')
2 data2 = pd.read_pickle(SAVE_PATH+'음성데이터전처리_2.pkl')
3 data3 = pd.read_pickle(SAVE_PATH+'음성데이터전처리_3.pkl')
4 data4 = pd.read_pickle(SAVE_PATH+'음성데이터전처리_4.pkl')
5
```

```
1 data=pd.concat([data1,data2])
```

```
1 data=pd.concat([data,data3])
```

```
1 data=pd.concat([data,data4])
```

```
1 # 이제 바로 사용 가능!
2 print(f"✅ MFCC 타입: {type(data['mfcc'].iloc[0])}")
3 print(f"✅ MFCC shape: {data['mfcc'].iloc[0].shape}")
```

- ✓ MFCC 타입: <class 'numpy.ndarray'>
- ✓ MFCC shape: (30, 5935)

```
1 data.isnull().sum()
```

```

0
emotion 0
start 0
end 0
text 0
mp3_files 0
label 0
mfcc 0
id 0
dtype: int64

```

```
1 data.info()
```

```
class "mpdas_core.frame.DataFrame">
Index: 2676 entries, 0 to 715
Data columns (total 8 columns):
 #   Column      Non-Null Count  Dtype
---  -
 0   emotion     2676 non-null   object
 1   start       2676 non-null   object
 2   end         2676 non-null   object
 3   text        2676 non-null   object
 4   mp3_files   2676 non-null   object
 5   label       2676 non-null   object
 6   mfcc        2676 non-null   object
 7   id          2676 non-null   object
dtypes: object(8)
memory usage: 202.2+ KB
```

```
1 data=data[['text','mfcc','label']]
```

1 data

	text	mfcc	label
0	네. 건강해요. 무릎이 까졌어요. 한 일주일 안아요. 아빠랑 같이 스키 때려요. 아...	[[-287.63055, -167.36935, -126.68648, -130.883...	슬픔
1	네. 건강요. 잔여 머리를 잘 맞았는게 중요하. 아파한대요. 이마가 뿔어져서...	[[-280.85858, -154.98929, -73.88041, -53.0979...	슬픔
2	안녕하. 아요. 제가 좋아하는 물고기 명상 할 때요. 제가 물고기를 엄청 좋아해...	[[-293.23975, -225.6564, -236.06064, -279.0968...	슬픔
3	네. 다치어요. 손바닥아랑 종아리랑 얼굴아랑 등아요. 병환은 안 갠데도 멍들고 피...	[[-323.36456, -284.55374, -242.94849, -172.724...	불안
4	허벅지랑 입이 아파요. 세뭇마가 거것할말고다 때려요요. 허벅지는 피멍 들어고 ...	[[-293.35422, -204.26611, -198.02936, -221.593...	불안
...	...	...	...
711	배가 아파요. 모르겠어요. 배 잔재가 아픈 것 같아요. 한 달 남는 것 같아요. 일...	[[-282.7017, -228.5789, -254.6171, -274.73004...	슬픔
712	아픈 곳 없어요. 없어요. 친구들이랑 놀 때 줄거워요. 그냥 친구들 줄거워요. 하왔...	[[-224.39046, -155.57378, -164.24448, -241.605...	슬픔
713	모르겠어요. 네. 없는데요. 없는데요. 예들거요 보드게임 할 때요. 머리를 써서 게...	[[-355.52365, -284.78622, -282.87534, -286.180...	분노
714	네. 아픈 곳 없이 건강해요. 없어요. 사진 찍는 게 좀 즐거워요. 친구들 사귀도...	[[-302.62863, -213.26546, -196.8219, -176.1394...	기쁨
715	아픈 곳 없어요. 그런 것도 없어요. 저는 소심 올을 때까 제일 즐거워요. 그냥 내...	[[-202.66762, -112.82149, -89.933014, -110.204...	슬픔

다음 단계: [data 변수로 코드 생성](#) [New interactive sheet](#)

```
1 for i in data['mfcc']:
2     print(i.shape)
3     break
```

(30. 5935)

```
1 data['mfcc'][0].shape
```

(4.)

▼ PHQ-9

```
1 direct_core = [  
2     "자살 생각이 든다", "죽고싶다", "죽는게 낫다",  
3     "자해 생각이 든다", "자해할 생각이다"  
4 ]
```

```
1 core_list = [  
2     "우울하다", "희망이 없다", "졸거지 않다",  
3     "행동이 느려졌다", "말이 느려졌다",  
4     "인상에 집중을 못한다", "실패했다",  
5     "가족을 실망 시켰다", "기운이 없다", "피곤하다"  
6 ]  
7
```

```
1 indirect_list = [  
2     "흥미가 없다", "흥미가 떨어지다",  
3     "식욕이 줄다", "입맛이 없다", "많이 먹다",  
4     "잠들기 어렵다", "잠을 너무 많이 잔다",  
5     "가만히 있을 못한다", "안절부절하다", "잘못하고있다"  
6 ]
```

```
1 phq9_symptoms={'direct_core':direct_core,'core_list':core_list,'indirect_list':indirect_list }
```

```
1 phq9_keys = list(phq9_symptoms.keys())
```

1 phq9\_keys

```
['direct_core', 'core_list', 'indirect_list']
```

## 키워드 점수 가중치

- phq-9 스코어 제외

## 형태소 분석

```
- phq9_symptoms 단어들과 정제된 텍스트 데이터를 각각 형태소 분석해준다
```

```
1 # #Mecab 설치 (Colab)
2 # !pip install konlpy
3 # !pip install mecab-python3
4 # !bash <curl -s https://raw.githubusercontent.com/konlpy/konlpy/master/scripts/mecab.sh>
```

```
1 # from konlpy.tag import Mecab
2
3 # # Mecab 객체 생성
4 # mecab = Mecab()
```

```
1 # pos_phq9={}
2
3 # for i in phq9_keys:
4 #     #print(phq9_symptoms[i])
5
6 #     steam_list=[]
7
8 #     for j in phq9_symptoms[i]:
9 #         #print(j)
10 #         pos=mecab.pos(j)
11 #         #print(pos)
12
13 #         steam=[]
14 #         for word, tag in pos:
15
16 #             #print(word, tag)
17
18 #             if tag.startswith('VV') or tag.startswith('VA'): # VV(동사), VA(형용사)의 경우 여간만 사용
19 #                 steam.append(word)
20 #             elif tag.startswith('NN'): # NNG(일반명사), NNP(고유명사) 등 명사의 경우 단어 자체를 사용
21 #                 steam.append(word)
22
23 #             #print(steam)
24
25 #             steam_list.append(' '.join(steam))
26 #             #print(steam_list)
27
28 #     pos_phq9[i]=steam_list
29
30
31 # print(pos_phq9)
```

```
1 # pos_phq9
```

```
1 # def pos(i):
2
3 #     steam_list=[]
4
5 #     pos=mecab.pos(i)
6 #     #print(pos)
7
8 #     steam=[]
9 #     for word, tag in pos:
10
11 #         #print(word, tag)
12
13 #         if tag.startswith('VV') or tag.startswith('VA'): # VV(동사), VA(형용사)의 경우 여간만 사용
14 #             steam.append(word)
15 #         elif tag.startswith('NN'): # NNG(일반명사), NNP(고유명사) 등 명사의 경우 단어 자체를 사용
16 #             steam.append(word)
17
18 #         #print(steam)
19
20 #     return ' '.join(steam)
21
```

```
1 # data['text_pos']=data['text'].apply(lambda x: pos(x))
```

```
1 # data
```

```
1 # data['label'].value_counts()
```

## phq9\_score 생성

```
1 # phq9_keys
```

```
1 # import numpy as np
2
3 # def create_phq9_vector(text):
4 #     phq9_score=0
5
6 #     for i,v in enumerate(phq9_keys):
7
8 #         if v=='direct_core':
9
10 #             for j in pos_phq9[v]:
11
12 #                 if j in text:
13 #                     phq9_score+=3.0
14
15 #             elif v=='core_list':
16
17 #                 for j in pos_phq9[v]:
18
19 #                     if j in text:
20 #                         phq9_score+=2.0
21
22 #                 else:
23
24 #                     for j in pos_phq9[v]:
25
26 #                         if j in text:
27 #                             phq9_score+=1.0
28
29 #             return phq9_score
30
31 #
32
```

```
1 # data['phq9_score']=data['text_pos'].apply(lambda x: create_phq9_vector(x))
```

```
1 # data
```

## 의미 유사도 가중치

## 텍스트 데이터 벡터화

```
1 # max_length 정하기
2
3 data['text_length']=data['text'].apply(lambda x: len(x))
```

```
1 batch_size=32
2
3
4 max_length=int(data['text_length'].quantile(0.90))
5 print('90인 지점:{}'.format(max_length))
6 print('최대 텍스트 길이: {}'.format(data['text_length'].max()))
7 print('평균 텍스트 길이: {}'.format(data['text_length'].mean()))
8
9
```

90인 지점:1479  
최대 텍스트 길이: 3405  
평균 텍스트 길이: 1000.46140472679

```
1 import torch
2 import torch.nn.functional as F
3 from transformers import AutoTokenizer, AutoModel
4 from tqdm import tqdm
5 import numpy as np
6 from tqdm import tqdm
7
8
9 device = torch.device("cuda" if torch.cuda.is_available() else "cpu")
10 print("Using device: {}".format(device))
11
12 MODEL_NAME = "klue/roberta-base"
13 tokenizer = AutoTokenizer.from_pretrained(MODEL_NAME)
14 klue = AutoModel.from_pretrained(MODEL_NAME).to(device)
```

Using device: cuda  
/usr/local/lib/python3.12/dist-packages/huggingface\_hub/utils/\_auth.py:94: UserWarning:  
The secret `HF\_TOKEN` does not exist in your Colab secrets.  
To authenticate with the Hugging Face Hub, create a token in your settings tab (<https://huggingface.co/settings/tokens>), set it as secret in your Google Colab and restart your session.  
You will be able to reuse this secret in all of your notebooks.  
Please note that authentication is recommended but still optional to access public models or datasets.  
warnings.warn(  
tokenizer\_config.json: 100% 375/375 [00:00<00:00, 44.1kB/s]  
  
vocab.txt: 248k/? [00:00<00:00, 17.1MB/s]  
  
tokenizer.json: 752k/? [00:00<00:00, 46.2MB/s]  
  
special\_tokens\_map.json: 100% 173/173 [00:00<00:00, 19.2kB/s]  
  
config.json: 100% 546/546 [00:00<00:00, 49.6kB/s]  
  
model.safetensors: 100% 443M/443M [00:06<00:00, 74.5MB/s]  
Some weights of RobertaModel were not initialized from the model checkpoint at klue/roberta-base and are newly initialized: ['pooler.dense.bias', 'pooler.dense.weight']  
You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.

```
1 def encode_texts(texts, max_length, batch_size):
2
3     if isinstance(texts, list):
4         texts = texts.tolist()
5
6     with torch.no_grad():
7
8         text_vecs=[]
9         for i in tqdm(range(0, len(texts), batch_size)):
10
11             batch=texts[i:i+batch_size]
12
13             token=tokenizer(batch,
14                             padding=True, # 짧은 문장을 패딩 추가
15                             truncation=True, # 긴 문장을 잘라냄
16                             max_length=max_length,
17                             return_tensors="pt" # 파이토치 텐서로 반환
18             )
19
20
21             input_ids=token['input_ids'].to(device)
22             attention_mask=token['attention_mask'].to(device)
23
24             output=klue.forward(input_ids, attention_mask )
25             last_hidden_state=output.last_hidden_state
26
27
28             mask=attention_mask.unsqueeze(-1).float() # 패딩 제외하기
29             mean=(last_hidden_state*mask).sum(dim=-1)/mask.sum(dim=-1).clamp(min=1e-9) # 평균 계산
30             mean=F.normalize(mean, p=2, dim=-1) # 단위 벡터로 만들기
31
32             text_vecs.append(mean.detach().cpu())
33
34         text_vecs=torch.cat(text_vecs, dim=0) # 리스트-> 텐서화
35
36
37     return text_vecs
```

```
1 print('모델 최대 길이: {}'.format(klue.config.max_position_embeddings)) , print('현재 max_length: {}'.format(max_length))
```

모델 최대 길이: 514  
현재 max\_length: 1479  
(None, None)

▼ phq-9 단어 벡터화

```
1 phq9_words=[]
2
3 for i in phq9_symptoms:
4     for v in phq9_symptoms[i]:
5         phq9_words.append(v)
```

```
1 phq9_emb=encode_texts(phq9_words, len(phq9_words), batch_size)
```

100%|██████████| 1/1 [00:00<00:00, 1.40it/s]

```
1 if max_length > 512:
2     max_length=512
3 else:
4     pass
```

```
1 text_emb = encode_texts(data['text'], max_length, batch_size)
```

100%|██████████| 90/90 [01:29<00:00, 1.01it/s]

▼ 내적

```
1 cos_sim=(text_emb @ phq9_emb.T).numpy()
2
3 max_sim=cos_sim.max(axis=1)
```

```
1 data['similarity']=max_sim
```

```
1 data.head()
```

	text	mfcc	label	text_length	similarity	
0	네. 건강해요. 무릎이 까졌어요. 한 일주일 전이요. 아배랑 같이 살 때부터요. 아...	[[-287.63055, -167.36935, -126.68648, -130.883...	슬픔	826	0.511867	ML
1	네. 일주일 전에 머리를 많이 맞았는데 계속 아파요. 아배한테요. 이마가 찾아져서 ...	[[-280.85858, -154.98929, -73.88041, -53.0979...	슬픔	781	0.509609	
2	건강해요. 아니요. 제가 좋아하는 물고기 영상 볼 때요. 제가 물고기를 엄청 좋아해...	[[-293.23975, -226.5664, -236.06046, -279.0968...	슬픔	1145	0.494879	
3	네. 다쳤어요. 손바닥이랑 종아리랑 얼굴이랑 통이요. 병원은 안 갔는데 망들고 피...	[[-323.36456, -284.55374, -242.94849, -172.724...	불안	899	0.472573	
4	허벅지랑 입이 아파요. 세암마가 거짓말한다고 패웠어요. 허벅지는 피랄 형이 들고 ...	[[-293.35422, -204.26611, -198.02936, -221.593...	불안	1514	0.495485	

다음 단계: [data 변수로 코드 생성](#) [New interactive sheet](#)

▼ 최종 점수 계산

- total\_all = ((np.array(kw\_scores\_all) \* W\_KW) + (max\_sim\_all \* W\_SEM)) \* TARGET\_CATS

- W\_KW = 1.0 # 키워드 점수 가중치 자살
- W\_SEM = 0.6 # 의미 유사도 가중치
- TARGET\_CATS = ["학업 및 진로", "학교폭력/따돌림"] CATEGORY\_BOOST = 1.5

```
1 # W_KW=1.0
2 # W_SEM= 0.6
```

```
1 #concat_data['TARGET_CATS']=concat_data['상황키워드'].apply(lambda x: 1.5 if x in ["학업 및 진로", "학교폭력/따돌림"] else 1.0)
```

```
1 # data['phq9_total_score']=((data['phq9_score'])*W_KW)+(data['similarity']*W_SEM))
```

```
1 # data.columns
```

```
1 # data.head()
```

```
1 data=data[['text','similarity','mfcc','label']]
```

```
1 data['label'].value_counts()
```

	count
label	
슬픔	1450
불안	659
기쁨	561
분노	94
당황	89
상처	23

dtype: int64

```
1 data.head()
```

	text	similarity	mfcc	label
0	네. 건강해요. 무릎이 까졌어요. 한 일주일 전이요. 아배랑 같이 살 때부터요. 아...	0.511867	[[-287.63055, -167.36935, -126.68648, -130.883...	슬픔
1	네. 일주일 전에 머리를 많이 맞았는데 계속 아파요. 아배한테요. 이마가 찢어져서 ...	0.509609	[[-280.85858, -154.98929, -73.88041, -53.0979,....	슬픔
2	건강해요. 아니요. 제가 좋아하는 물고기 영상 볼 때요. 제가 물고기를 엄청 좋아해...	0.494879	[[-293.23975, -226.5664, -236.06046, -279.0968...	슬픔
3	네. 다쳤어요. 손바닥이랑 종아리랑 얼굴이랑 등이요. 병원은 안 갔는데 엉덩고 피...	0.472573	[[-323.36456, -284.55374, -242.94849, -172.724...	불안
4	허벅지랑 입이 아파요. 새얼마가 거짓말한다고 때렸어요. 허벅지는 피랑 발이 들고 ...	0.495485	[[-293.35422, -204.26611, -198.02936, -221.593...	불안

다음 단계: [data 변수로 코드 생성](#) [New interactive sheet](#)

mfcc(max length) 패딩

```
1 # 라이브러리 임포트
2 import numpy as np
3 import pandas as pd
4 from sklearn.preprocessing import LabelEncoder
5 from sklearn.model_selection import train_test_split
6 from imblearn.over_sampling import SMOTE
7 import torch
8 import torch.nn as nn
9 import torch.optim as optim
10 from torch.utils.data import TensorDataset, DataLoader
11 from tqdm import tqdm
12 import matplotlib.pyplot as plt
```

```
1 ## mfcc 최대 길이
2 time_steps = [arr.shape[1] for arr in data['mfcc']]
3 max_time = max(time_steps)
4 percentile_90 = int(np.percentile(time_steps, 90))
5 mean_time = np.mean(time_steps)
6
7 print(f"최대 길이: {max_time}")
8 print(f"90% 분위수: {percentile_90}")
9 print(f"평균 길이: {mean_time:.1f}")
10
11 # 90% 분위수 사용
12 MAX_TIME_STEPS = percentile_90
13
```

최대 길이: 18000  
90% 분위수: 8144  
평균 길이: 5648.4

```
1 # 2. 패딩 함수
2 def pad_mfcc(mfcc_array, max_length):
3
4     current_length = mfcc_array.shape[1]
5
6     if current_length < max_length:
7         # Zero padding
8         pad_width = ((0, 0), (0, max_length - current_length))
9         return np.pad(mfcc_array, pad_width, mode='constant', constant_values=0)
10     else:
11         # Truncate
12         return mfcc_array[:, :max_length]
```

```
1 data['mfcc_padded'] = data['mfcc'].apply(lambda x: pad_mfcc(x, MAX_TIME_STEPS))
```

모델링

multimodal

```
1 from transformers import AutoTokenizer
2 import numpy as np
```

```
1 data['text']
```

	text
0	네. 건강해요. 무릎이 까졌어요. 한 일주일 전이요. 아배랑 같이 살 때부터요. 아...
1	네. 일주일 전에 머리를 많이 맞았는데 계속 아파요. 아배한테요. 이마가 찢어져서 ...
2	건강해요. 아니요. 제가 좋아하는 물고기 영상 볼 때요. 제가 물고기를 엄청 좋아해...
3	네. 다쳤어요. 손바닥이랑 종아리랑 얼굴이랑 등이요. 병원은 안 갔는데 엉덩고 피...
4	허벅지랑 입이 아파요. 새얼마가 거짓말한다고 때렸어요. 허벅지는 피랑 형이 들고 ...
...	...
711	배가 아파요. 모르겠어요. 배 전체가 아픈 것 같아요. 한 달 넘은 것 같아요. 일...
712	아픈 곳 없어요. 없어요. 친구들이랑 놀 때 즐거워요. 그냥 친구들 즐거워요. 화났...
713	모르겠어요. 네. 없는데요. 없는데요. 애들하고 보드게임 할 때요. 머리를 써서 계...
714	네. 아픈 곳 없이 건강해요. 없어요. 사진 찍고 노는 게 즐거워요. 친구들 사진도...
715	아픈 곳 없어요. 그런 적도 없어요. 저는 소설 읽을 때가 제일 즐거워요. 그냥 내...

2876 rows × 1 columns

dtype: object

```
1 # Kiu 토큰라이저 로드
2 tokenizer = AutoTokenizer.from_pretrained('kiue/roberta-base')
```

```
1 all_text_token_length=[]
```

```
1 for text in data['text']:
2     encoding=tokenizer(text, add_special_tokens=True)
3     all_text_token_length.append(len(encoding['input_ids']))
4
5 print(f'총 {len(all_text_token_length)}개의 문장에 대한 토큰 길이 계산 완료')
6 print(f'예시 앞 5개 문장길이 {all_text_token_length[:5]}')
```

Token indices sequence length is longer than the specified maximum sequence length for this model (605 > 512). Running this sequence through the model will result in indexing errors  
총 2876개의 문장에 대한 토큰 길이 계산 완료  
예시 앞 5개 문장길이 [417, 417, 605, 474, 821]

```
1 print('모든 문장에서')
2 print(f'토큰 길이 최댓값은 {max(all_text_token_length)} 이다. ')
3 print(f'토큰 길이 최솟값은 {min(all_text_token_length)} 이다. ')
4
5 print(f'토큰 길이 평균은 {np.mean(all_text_token_length)} 이다. ')
6 print(f'토큰 길이 표준편차는 {np.std(all_text_token_length)} 이다. ')
7
8
9 print("-" * 30)
10 print(f'90% 지점의 길이: {np.percentile(all_text_token_length, 90)}')
11 print(f'95% 지점의 길이: {np.percentile(all_text_token_length, 95)}')
12 print(f'99% 지점의 길이: {np.percentile(all_text_token_length, 99)}')
```

모든 문장에서  
토큰 길이 최댓값은 1793 이다.  
토큰 길이 최솟값은 200 이다.  
토큰 길이 평균은 528.888915599443 이다.  
토큰 길이 표준편차는 184.70196794135694 이다.

90% 지점의 길이: 784.0  
95% 지점의 길이: 890.25  
99% 지점의 길이: 1120.0

```
1 text_max_length=890.25
```

```
1 if text_max_length>512:
2     text_max_length=512
```

```
1 text_max_length
```

512

## ▼ 데이터로드 함수

```
1 from transformers import AutoModel, AutoTokenizer
2 from sklearn.preprocessing import LabelEncoder
3 from torch.utils.data import Dataset, DataLoader
4 from sklearn.model_selection import train_test_split
5 import random
6 import copy
7 from torch.utils.data import Dataset, DataLoader, WeightedRandomSampler
8
9 batch_size=32
```

```
1 def multi_modal_data_load(text, max_length):
2
3     tokenizer = AutoTokenizer.from_pretrained('kiue/roberta-base')
4
5     label_encoder = LabelEncoder()
6     label_encoded = label_encoder.fit_transform(text['label'])
7     text = text.copy()
8     text['label_encoded'] = label_encoded
9
10    label_count = text['label'].nunique()
11
12    print(f'클래스 수: {label_count}')
13    for idx, label_name in enumerate(label_encoder.classes_):
14        print(f'{idx}: {label_name}')
15
16
17    train_idx, test_idx = train_test_split(
18        np.arange(len(text)),
19        test_size=0.3,
20        stratify=text['label_encoded'],
21        random_state=42
22    )
23
24    train_data = text.iloc[train_idx].reset_index(drop=True)
25    test_data = text.iloc[test_idx].reset_index(drop=True)
26
27
28
29
30
31
32
33    # =====
34    # 🟡 [핵심] WeightedRandomSampler 설정
35    # 데이터프레임을 분리하지 않고, 불균형한 데이터를 균형 잡히게 뽑아줍니다.
36    # =====
37
38    # 1. 클래스별 샘플 수 계산
39    class_counts = train_data['label_encoded'].value_counts().sort_index()
40
41    # 2. 클래스별 가중치 계산 (개수가 적을수록 가중치가 높음)
42    # weight = 1 / count
43    class_weights = 1.0 / class_counts
44    class_weights = torch.tensor(class_weights.values, dtype=torch.float)
45
46    # 3. 각 샘플(Row)마다 가중치 부여
47    # 예: 우물쭈м 데이터는 가중치 10, 일반 데이터는 가중치 1
48    sample_weights = [class_weights[label] for label in train_data['label_encoded']]
49    sample_weights = torch.tensor(sample_weights, dtype=torch.float)
50
51    # 4. 샘플러 생성
52    # num_samples를 지정하여 전체 데이터 크기를 조절할 수 있음 (여기선 원본 크기 유지하거나 늘릴 수 있음)
53    # 보통 불균형 해소를 위해 충분히 뽑기 위해 len(train_data) 그대로 사용하거나 늘림.
54    sampler = WeightedRandomSampler(
55        weights=sample_weights,
56        num_samples=len(train_data), # 혹은 len(train_data) * 2 등으로 늘려도 RNN 안 터짐
57        replacement=True
58    )
59    # =====
60
61
62
63
64
65
66    # Dataset 생성
67    train_dataset = TextDataset(
68        texts=train_data['text'],
69        phq9_features=train_data[['similarity']],
70        mfcc=train_data['mfcc_padded'],
71        labels=train_data['label_encoded'],
72        tokenizer=tokenizer,
73        max_length=max_length,
74        augment=True
75    )
76
77    test_dataset = TextDataset(
78        texts=test_data['text'],
79        phq9_features=test_data[['similarity']],
80        mfcc=test_data['mfcc_padded'],
81        labels=test_data['label_encoded'],
82        tokenizer=tokenizer,
83        max_length=max_length,
84        augment=False
85    )
```

```

86
87
88
89 # DataLoader
90 train_loader = DataLoader(train_dataset, batch_size=batch_size, sampler=sampler, shuffle=False)
91 test_loader = DataLoader(test_dataset, batch_size=batch_size, shuffle=False)
92
93 print(f"👁️ 훈련 데이터: {len(train_dataset)}개")
94
95 print(f"👁️ 테스트 데이터: {len(test_dataset)}개")
96
97 return train_loader, test_loader, label_count

```

```

1
2 class TextDataset(Dataset):
3     def __init__(self, texts, phq9_features, mfcc, labels, tokenizer, max_length, augment=False):
4         self.texts = texts.reset_index(drop=True) # 확실하게 리셋
5         self.labels = labels.reset_index(drop=True) # 확실하게 리셋
6         self.tokenizer=tokenizer
7         self.max_length=int(max_length)
8         self.phq9_features=phq9_features.reset_index(drop=True)
9         self.mfcc = mfcc.reset_index(drop=True)
10
11         self.augment = augment #증강처리
12
13     def __len__(self):
14         return len(self.texts)
15
16
17
18     # --- 내부 증강 함수 ---
19     def augment_mfcc(self, mfcc_data):
20         aug_mfcc = copy.deepcopy(mfcc_data)
21         noise = np.random.normal(0, 0.02, aug_mfcc.shape)
22         return aug_mfcc + noise
23
24     def augment_text(self, text):
25         words = text.split()
26         if len(words) <= 1: return text
27         if random.random() > 0.5:
28             idx1, idx2 = random.sample(range(len(words)), 2)
29             words[idx1], words[idx2] = words[idx2], words[idx1]
30         else:
31             if len(words) > 2:
32                 del words[random.randint(0, len(words)-1)]
33         return ' '.join(words)
34     # -----
35
36
37
38     def __getitem__(self, idx):
39         text = str(self.texts.iloc[idx])
40         phq9_features=self.phq9_features.iloc[idx].values.astype(np.float32)
41         label = int(self.labels.iloc[idx])
42
43         mfcc_data = self.mfcc.iloc[idx]
44
45
46         if self.augment:
47             text = self.augment_text(text)
48             mfcc_data = self.augment_mfcc(mfcc_data)
49
50
51
52
53
54         mfcc_data = np.expand_dims(mfcc_data, axis=0)
55
56
57         encoding=self.tokenizer.encode_plus(
58             text,
59             add_special_tokens=True,
60             max_length=self.max_length,
61             padding='max_length',
62             truncation=True,
63             return_attention_mask=True,
64             return_tensors='pt'
65         )
66
67         return (
68             encoding['input_ids'].flatten(),
69             encoding['attention_mask'].flatten(),
70             torch.tensor(phq9_features, dtype=torch.float32),
71             torch.tensor(mfcc_data, dtype=torch.float32),
72             torch.tensor(label, dtype=torch.long)
73         )

```

## ❏ 모델 함수

```

1 from transformers import AutoModel, AutoConfig
2 import torch.nn as nn
3 from tqdm import tqdm
4

```

```

1 class LSTMAudioClassifier(nn.Module):
2     def __init__(self, num_class, input_size=30, hidden_size=128, num_layers=2, dropout=0.3, target_length=500):
3         super(LSTMAudioClassifier, self).__init__()
4
5         self.target_length = target_length
6
7         self.lstm = nn.LSTM(
8             input_size=input_size,
9             hidden_size=hidden_size,
10            num_layers=num_layers,
11            batch_first=True,
12            dropout=dropout,
13            bidirectional=True
14        )
15
16        self.dropout = nn.Dropout(dropout)
17
18        self.classifier = nn.Linear(hidden_size*2, num_class)
19
20    def forward(self, mfcc):
21        # mfcc shape: (batch, 1, 30, 8144)
22        x = mfcc.squeeze(1) # (batch, 30, 8144)
23
24        # Adaptive Average Pooling으로 시퀀스 길이 축소
25        x = F.adaptive_avg_pool1d(x, output_size=self.target_length)
26        x = x.permute(0, 2, 1)
27
28        lstm_out, _ = self.lstm(x)
29        last_output = lstm_out[:, -1, :]
30
31        x = self.dropout(last_output)
32        y_pred = self.classifier(x)
33
34        return y_pred

```

```

1 class klueClassifier(nn.Module):
2     def __init__(self, num_class, num_layers_to_train=3, dropout=0.3):
3         super(klueClassifier, self).__init__()
4
5         self.klue=AutoModel.from_pretrained('klue/roberta-base')
6         config= AutoConfig.from_pretrained('klue/roberta-base')
7         hidden_size=config.hidden_size
8
9         # =====
10        # 부분 파인튜닝
11        total_layers = 12 # klue는 12개 레이어
12        layers_to_freeze = total_layers - num_layers_to_train
13
14        for param in self.klue.embeddings.parameters():
15            param.requires_grad = False
16
17        # 2) 처음 N개 레이어 freeze
18        for i in range(layers_to_freeze):

```

```

19         for param in self.klue.encoder.layer[i].parameters():
20             param.requires_grad = False
21         # =====
22
23
24         self.phq9_feature_layer=nn.Linear(1,16)
25
26         self.dropout=nn.Dropout(dropout)
27         self.classifier= nn.Linear(hidden_size+16, num_class)
28
29
30
31
32     def forward(self, input_ids, attention_mask, phq9_features):
33
34         output=self.klue(input_ids=input_ids, attention_mask=attention_mask)
35         cls_token=output.pooler_output
36
37
38         phq9=self.phq9_feature_layer(phq9_features)
39         phq9=torch.relu(phq9)
40         combined =torch.cat([cls_token, phq9], dim=1)
41
42
43         x=self.dropout(combined)
44         y_pred=self.classifier(x)
45
46
47         return y_pred
48
49

```

```

1 class MultiModalClassifier(nn.Module):
2     def __init__(self, num_class, text_num_layers_to_train=3, audio_input_size=30, audio_hidden_size=128, audio_target_length=500):
3         super(MultiModalClassifier, self).__init__()
4
5         # 텍스트 + PHQ9 모델
6         self.text_model = klueClassifier(
7             num_class=num_class,
8             num_layers_to_train=text_num_layers_to_train
9         )
10
11        # 음성(MFCC) 모델
12        self.audio_model = LSTMAudioClassifier(
13            num_class=num_class,
14            input_size=audio_input_size,
15            hidden_size=audio_hidden_size,
16            target_length=audio_target_length
17        )
18
19    def forward(self, input_ids, attention_mask, phq9_features, mfcc):
20        text_y = self.text_model(input_ids, attention_mask, phq9_features)
21        audio_y = self.audio_model(mfcc)
22
23        final_y = (text_y + audio_y) / 2.0
24
25        return final_y

```

```

1
2 def multimodal_train(train_loader, model, criterion, optimizer, device, epochs=6):
3
4     history = {'Epoch': [], 'loss': []}
5
6     for i in range(epochs):
7         model.train()
8         total_loss=0
9
10        for x, attention_mask, phq9, mfcc, y in tqdm(train_loader):
11
12            x= x.to(device)
13            attention_mask=attention_mask.to(device)
14            phq9=phq9.to(device)
15            mfcc=mfcc.to(device)
16            y= y.to(device)
17
18            y_pred=model(x, attention_mask, phq9, mfcc)
19            loss=criterion(y_pred, y)
20
21            optimizer.zero_grad()
22            loss.backward()
23
24            optimizer.step()
25
26            total_loss+=loss.item()
27
28        history['loss'].append(total_loss / len(train_loader))
29        history['Epoch'].append(i)
30
31        if i % 2 == 0:
32            print ('Epoch {}: Loss={total_loss/len(train_loader)}')
33
34        return history
35
36

```

## 모델평가 함수

```

1 from sklearn.metrics import(
2     accuracy_score,
3     f1_score,
4     precision_score,
5     recall_score,
6     classification_report,
7     confusion_matrix
8 )
9 import numpy as np
10
11

```

```

1 def multimodal_eval(test_loader, model, depression_classes, device=device, label_names=None ):
2     model.eval()
3
4     all_preds=[]
5     all_labels=[]
6
7     with torch.no_grad():
8         for x, attention_mask, phq9, mfcc, y in test_loader: # 37회
9             x = x.to(device)
10            attention_mask = attention_mask.to(device)
11            phq9=phq9.to(device)
12            mfcc=mfcc.to(device)
13
14            y_pred = model(x, attention_mask, phq9, mfcc) # attention_mask 포함
15            preds = torch.argmax(y_pred, dim=1)
16
17            all_preds.extend(preds.cpu().numpy())
18            all_labels.extend(y.cpu().numpy())
19
20
21
22        accuracy = accuracy_score(all_labels, all_preds)
23        f1_macro = f1_score(all_labels, all_preds, average='macro')
24        f1_weighted = f1_score(all_labels, all_preds, average='weighted')
25        cm = confusion_matrix(all_labels, all_preds)
26
27        print(f'📊 Accuracy: {accuracy:.4f}')
28        print(f'📊 Macro F1-Score: {f1_macro:.4f}')
29        print(f'📊 Weighted F1-Score: {f1_weighted:.4f}')
30        print(f'📊 Confusion Matrix:')
31        print(cm)
32
33
34
35        # =====
36        # 3. 우울 신호 집중 분석
37        # =====

```

```

38
39
40 print("출" + "="*60)
41 print(f"🔴 우울 신호 집중 분석 ({depression_classes})")
42 print("="*60)
43
44 # 이전 분류로 변환
45 all_labels_np = np.array(all_labels)
46 all_preds_np = np.array(all_preds)
47
48 y_true_binary = np.isin(all_labels_np, depression_classes).astype(int)
49 y_pred_binary = np.isin(all_preds_np, depression_classes).astype(int)
50
51 # Precision & Recall
52 precision = precision_score(y_true_binary, y_pred_binary, zero_division=0)
53 recall = recall_score(y_true_binary, y_pred_binary, zero_division=0)
54 f1 = f1_score(y_true_binary, y_pred_binary, zero_division=0)
55
56
57
58 # 실제 우울 신호인데 기타로 예측
59 false_negatives = np.sum((y_true_binary == 1) & (y_pred_binary == 0))
60 # True Positive
61 true_positives = np.sum((y_true_binary == 1) & (y_pred_binary == 1))
62 # 진짜 우울 신호
63 total_depression = np.sum(y_true_binary == 1)
64
65
66
67
68 print(f"출" + "="*60)
69 print(f"🔴 우울 신호 집중 분석 (불안 + 상처 + 슬픔)")
70 print(f"="*60)
71 print(f"✅ Precision: {precision:.4f}")
72 print(f"✅ Recall: {recall:.4f}")
73 print(f"✅ F1-Score: {f1:.4f}")
74 print(f"🔴 False Negative: {false_negatives}건 / {total_depression}건")
75 print(f"✅ True Positive: {true_positives}건 / {total_depression}건")
76
77
78 # Classification Report
79 if label_names: # = ['기쁨', '당황', '분노', '불안', '상처', '슬픔']
80     print(f"📊 Classification Report:")
81     print(classification_report(all_labels, all_preds, target_names=label_names))
82
83
84
85 return {
86     'accuracy': accuracy,
87     'f1_macro': f1_macro,
88     'f1_weighted': f1_weighted,
89     'confusion_matrix': cm,
90     'depression_precision': precision,
91     'depression_recall': recall,
92     'depression_f1': f1,
93     'false_negatives': false_negatives,
94     'true_positives': true_positives,
95     'total_depression': total_depression,
96 }
97

```

## ❏ 데이터 입력

```
1 total_result=[]
```

```

1 results={'task':'six_label_all_text_phq9_multimodal',
2         'text': 'all',
3         'label':'six',
4         'model':'multimodal'
5         }

```

```

1 max_length=text_max_length
2
3 batch_size=8 # 메모리 문제
4 epochs=6

```

```

1 from torch.utils.data import Dataset, DataLoader, WeightedRandomSampler
2
3 train_loader, test_loader, label_count=multimodal_data_load(data, max_length)

```

클래스 수: 6  
0: 기쁨  
1: 당황  
2: 분노  
3: 불안  
4: 상처  
5: 슬픔  
✅ 훈련 데이터: 2013개  
✅ 테스트 데이터: 863개

```

1 import torch.nn.functional as F
2
3 device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
4
5 MultiModal_model = MultiModalClassifier(
6     num_class=label_count,
7     text_num_layers_to_train=3,
8     audio_input_size=30,
9     audio_hidden_size=128,
10    audio_target_length=200
11 ).to(device)
12
13 MultiModal_criterion = nn.CrossEntropyLoss()
14 MultiModal_optimizer = torch.optim.AdamW(
15     MultiModal_model.parameters(),
16     lr=1e-5,
17     weight_decay=0.01
18 )
19
20 print(f"✅ 모델 생성 완료!")

```

Some weights of RobertaModel were not initialized from the model checkpoint at klue/roberta-base and are newly initialized: ['pooler.dense.bias', 'pooler.dense.weight']  
You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.  
✅ 모델 생성 완료!

```
1 multimodal_train(train_loader, MultiModal_model, MultiModal_criterion, MultiModal_optimizer, device, epochs=6)
```

```

100%|██████████| 252/252 [01:51<00:00, 2.251t/s]
Epoch 0: Loss=1.7649880581431918
100%|██████████| 252/252 [01:50<00:00, 2.271t/s]
100%|██████████| 252/252 [01:50<00:00, 2.271t/s]
Epoch 2: Loss=0.8907697631253136
100%|██████████| 252/252 [01:50<00:00, 2.271t/s]
100%|██████████| 252/252 [01:51<00:00, 2.271t/s]
Epoch 4: Loss=0.5823732987046242
100%|██████████| 252/252 [01:50<00:00, 2.281t/s]
{'Epoch': [0, 1, 2, 3, 4, 5],
 'loss': [1.7649880581431918,
1.2980793125572658,
0.8907697631253136,
0.6852923324183812,
0.5823732987046242,
0.5033164951536391]}

```

```

1 torch.save(MultiModal_model.state_dict(), SAVE_PATH + 'phase3_six_label_all_text_phq9_multimodal.pt')
2 print("모델 저장 완료")

```

모델 저장 완료

```

1 six_label_depression_classes = [3, 4, 5]
2 four_label_depression_classes = [1]

```

```
1 result=multimodal_eval(test_loader, MultiModal_model, six_label_depression_classes)
```

✅ Accuracy: 0.6466



Macro F1-Score: 0.4734  
Weighted F1-Score: 0.6442

Confusion Matrix:  
[[158 2 4 1 0 3]  
[ 14 6 2 2 0 3]  
[ 4 4 15 3 0 2]  
[ 12 1 2 162 0 21]  
[ 1 1 1 1 1 2]  
[ 42 15 36 124 2 216]]

우물 신호 집중 분석 ([3, 4, 5])

우물 신호 집중 분석 (불안 + 상처 + 슬픔)

Precision: 0.9742  
Recall: 0.8266  
F1-Score: 0.8943

False Negative: 111건 / 640건  
True Positive: 529건 / 640건

1 results.update(result)

1 total\_result.append(results)

```
1 import gc
2 del MultiModel_model
3 del MultiModel_optimizer
4 torch.cuda.empty_cache()
5 gc.collect()
```

4769

## Fine\_Tuning

### 데이터로딩 함수

1 max\_length

512

```
1 from transformers import AutoModel, AutoTokenizer
2 from sklearn.preprocessing import LabelEncoder
3 from torch.utils.data import Dataset, DataLoader
4 from sklearn.model_selection import train_test_split
5
6
7 batch_size=32
```

```
1 # data_phq9=data[['text', 'label', 'phq9_score', 'similarity', 'phq9_total_score']]
2
3 data_phq9 = data[['text', 'label', 'similarity']]
```

```
1
2 class TextDataset(Dataset):
3     def __init__(self, texts, phq9_features, labels, tokenizer, max_length, augment=False):
4         self.texts = texts.reset_index(drop=True) # 확실하게 리셋
5         self.labels = labels.reset_index(drop=True) # 확실하게 리셋
6         self.tokenizer=tokenizer
7         self.max_length=int(max_length)
8         self.phq9_features=phq9_features.reset_index(drop=True)
9         self.augment = augment
10
11     def __len__(self):
12         return len(self.texts)
13
14
15     # --- 내부 텍스트 증강 함수 ---
16     def augment_text(self, text):
17         words = text.split()
18         if len(words) <= 1: return text
19
20         # 50% 확률로 순서 섞기, 50% 확률로 단어 삭제
21         if random.random() > 0.5:
22             idx1, idx2 = random.sample(range(len(words)), 2)
23             words[idx1], words[idx2] = words[idx2], words[idx1]
24         else:
25             if len(words) > 2:
26                 del words[random.randint(0, len(words)-1)]
27             return ' '.join(words)
28         # -----
29
30
31
32
33     def __getitem__(self, idx):
34         text = str(self.texts.iloc[idx])
35
36         # [확인] Train 모드일 때만 텍스트 실시간 증강
37         if self.augment:
38             text = self.augment_text(text)
39
40
41
42         phq9_features=self.phq9_features.iloc[idx].values.astype(np.float32)
43         label = int(self.labels.iloc[idx])
44
45         encoding=self.tokenizer.encode_plus(
46             text,
47             add_special_tokens=True,
48             max_length=self.max_length,
49             padding='max_length',
50             truncation=True,
51             return_attention_mask=True,
52             return_tensors='pt'
53         )
54         return (
55             encoding['input_ids'].flatten(),
56             encoding['attention_mask'].flatten(),
57             torch.tensor(phq9_features, dtype=torch.float32),
58             torch.tensor(label, dtype=torch.long)
59         )
```

```
1 def FineTuning_data_load(text, max_length):
2
3     tokenizer = AutoTokenizer.from_pretrained('klue/roberta-base')
4
5     label_encoder = LabelEncoder()
6     label_encoded = label_encoder.fit_transform(text['label'])
7     text = text.copy()
8     text['label_encoded'] = label_encoded
9
10    label_count = text['label'].nunique()
11
12    print(f'클래스 수: {label_count}')
13    for idx, label_name in enumerate(label_encoder.classes_):
14        print(f' {idx}: {label_name}')
15
16
17    train_idx, test_idx = train_test_split(
18        np.arange(len(text)),
19        test_size=0.3,
20        stratify=text['label_encoded'],
21        random_state=42
22    )
23
24    train_data = text.iloc[train_idx].reset_index(drop=True)
25    test_data = text.iloc[test_idx].reset_index(drop=True)
26
27
```

```

28
29
30
31 print(" ⚠ 메모리 절약을 위해 WeightedRandomSampler(실시간 밸런싱)를 사용합니다.")
32
33 # =====
34 # 🟡 [핵심] WeightedRandomSampler 설정 (데이터 복사 없이 밸런싱)
35 # =====
36
37 # 1. 클래스별 샘플 수 계산
38 class_counts = train_data['label_encoded'].value_counts().sort_index()
39
40 # 2. 클래스별 가중치 계산 (개수가 적을수록 가중치 높음)
41 class_weights = 1.0 / class_counts
42 class_weights = torch.tensor(class_weights.values, dtype=torch.float)
43
44 # 3. 각 샘플마다 가중치 부여
45 sample_weights = [class_weights[label] for label in train_data['label_encoded']]
46 sample_weights = torch.tensor(sample_weights, dtype=torch.float)
47
48 # 4. 샘플러 생성 (데이터를 늘리고 싶으면 num_samples를 len(train_data) * 2 등으로 설정)
49 sampler = WeightedRandomSampler(
50     weights=sample_weights,
51     num_samples=len(train_data), # 원본 데이터 개수 유지 (원하면 늘려도 됨)
52     replacement=True
53 )
54 # =====
55
56
57
58
59
60 # Dataset 생성
61 train_dataset = TextDataset(
62     texts=train_data['text'],
63     phq9_features=train_data[['similarity']],
64     labels=train_data['label_encoded'],
65     tokenizer=tokenizer,
66     max_length=max_length,
67     augment=True
68 )
69
70 test_dataset = TextDataset(
71     texts=test_data['text'],
72     phq9_features=test_data[['similarity']],
73     labels=test_data['label_encoded'],
74     tokenizer=tokenizer,
75     max_length=max_length,
76     augment=False
77 )
78
79 # DataLoader
80 train_loader = DataLoader(train_dataset, batch_size=batch_size, shuffle=False, sampler=sampler)
81 test_loader = DataLoader(test_dataset, batch_size=batch_size, shuffle=False)
82
83 print(f"🟢 훈련 데이터: {len(train_dataset)}개")
84 print(f"🟢 테스트 데이터: {len(test_dataset)}개")
85
86 return train_loader, test_loader, label_count

```

## ▼ 모델 함수

```

1 from transformers import AutoModel, AutoConfig
2 import torch.nn as nn
3 from tqdm import tqdm
4

```

```

1 class KluEClassifier(nn.Module):
2     def __init__(self, num_class, num_layers_to_train=3, dropout=0.3):
3         super(KluEClassifier, self).__init__()
4
5         self.klue=AutoModel.from_pretrained('klue/roberta-base')
6         config= AutoConfig.from_pretrained('klue/roberta-base')
7         hidden_size=config.hidden_size
8
9         # =====
10        # 부분 피인류닝
11        total_layers = 12 # klue는 12개 레이어
12        layers_to_freeze = total_layers - num_layers_to_train
13
14        for param in self.klue.embeddings.parameters():
15            param.requires_grad = False
16
17        # 2) 처음 N개 레이어 freeze
18        for i in range(layers_to_freeze):
19            for param in self.klue.encoder.layer[i].parameters():
20                param.requires_grad = False
21
22        # =====
23
24        self.phq9_feature_layer=nn.Linear(1,16)
25
26        self.dropout=nn.Dropout(dropout)
27        self.classifier= nn.Linear(hidden_size+16, num_class)
28
29
30
31
32 def forward(self, input_ids, attention_mask, phq9_features):
33
34     output=self.klue(input_ids=input_ids, attention_mask=attention_mask)
35     cls_token=output.pooler_output
36
37
38     phq9=self.phq9_feature_layer(phq9_features)
39     phq9=torch.relu(phq9)
40     combined =torch.cat([cls_token, phq9], dim=1)
41
42
43     x=self.dropout(combined)
44     y_pred=self.classifier(x)
45
46
47     return y_pred
48
49

```

```

1
2 def FineTuning_train(train_loader, model, criterion, optimizer, device=device, epochs=3):
3
4     history = {'Epoch': [], 'loss': []}
5
6     for i in range(epochs):
7         model.train()
8         total_loss=0
9
10        for x, attention_mask, phq9, y in tqdm(train_loader):
11
12            x= x.to(device)
13            attention_mask=attention_mask.to(device)
14            phq9=phq9.to(device)
15            y= y.to(device)
16
17            y_pred=model(x, attention_mask, phq9)
18            loss=criterion(y_pred, y)
19
20            optimizer.zero_grad()
21            loss.backward()
22
23            optimizer.step()
24
25            total_loss+=loss.item()
26
27
28        history['loss'].append(total_loss / len(train_loader))
29        history['Epoch'].append(i)
30

```

```

31         if i % 2 == 0:
32             print (f'Epoch {i}: Loss={total_loss/len(train_loader)}')
33
34     return history
35

```

## 모델평가 함수

```

1  from sklearn.metrics import(
2      accuracy_score,
3      f1_score,
4      precision_score,
5      recall_score,
6      classification_report,
7      confusion_matrix
8  )
9  import numpy as np
10
11

```

```

1  def FineTuning_eval(test_loader, model, depression_classes, device=device, label_names=None):
2      model.eval()
3
4      all_preds=[]
5      all_labels=[]
6
7      with torch.no_grad():
8          for x, attention_mask, phq9, y in test_loader: # 3개!
9              x = x.to(device)
10             attention_mask = attention_mask.to(device)
11             phq9=phq9.to(device)
12
13             y_pred = model(x, attention_mask, phq9) # attention_mask 포함
14             preds = torch.argmax(y_pred, dim=1)
15
16             all_preds.extend(preds.cpu().numpy())
17             all_labels.extend(y.cpu().numpy())
18
19
20
21     accuracy = accuracy_score(all_labels, all_preds)
22     f1_macro = f1_score(all_labels, all_preds, average='macro')
23     f1_weighted = f1_score(all_labels, all_preds, average='weighted')
24     cm = confusion_matrix(all_labels, all_preds)
25
26     print(f'📊 Accuracy: {accuracy:.4f}')
27     print(f'📊 Macro F1-Score: {f1_macro:.4f}')
28     print(f'📊 Weighted F1-Score: {f1_weighted:.4f}')
29     print(f'📊 Confusion Matrix:')
30     print(cm)
31
32
33
34     # =====
35     # 3. 우울 신호 집중 분석
36     # =====
37
38
39     print("\n" + "="*60)
40     print(f'🔴 우울 신호 집중 분석 ({depression_classes})')
41     print("="*60)
42
43
44     # 이진 분류로 변환
45     all_labels_np = np.array(all_labels)
46     all_preds_np = np.array(all_preds)
47
48     y_true_binary = np.isin(all_labels_np, depression_classes).astype(int)
49     y_pred_binary = np.isin(all_preds_np, depression_classes).astype(int)
50
51     # Precision & Recall
52     precision = precision_score(y_true_binary, y_pred_binary, zero_division=0)
53     recall = recall_score(y_true_binary, y_pred_binary, zero_division=0)
54     f1 = f1_score(y_true_binary, y_pred_binary, zero_division=0)
55
56
57
58     # 실제 우울 신호인데 기대로 예측
59     false_negatives = np.sum((y_true_binary == 1) & (y_pred_binary == 0))
60     # True Positive
61     true_positives = np.sum((y_true_binary == 1) & (y_pred_binary == 1))
62     # 전체 우울 신호
63     total_depression = np.sum(y_true_binary == 1)
64
65
66
67     print(f'\n{"="*60}')
68     print(f'🔴 우울 신호 집중 분석 (불안 + 상처 + 슬픔)')
69     print(f'\n{"="*60}')
70     print(f'📊 Precision: {precision:.4f}')
71     print(f'📊 Recall: {recall:.4f}')
72     print(f'📊 F1-Score: {f1:.4f}')
73     print(f'📊 False Negative: {false_negatives}건 / {total_depression}건')
74     print(f'📊 True Positive: {true_positives}건 / {total_depression}건')
75
76
77
78     # Classification Report
79     if label_names: # = ['기쁨', '당황', '분노', '불안', '상처', '슬픔']
80         print(f'📊 Classification Report:')
81         print(classification_report(all_labels, all_preds, target_names=label_names))
82
83
84     return {
85         'accuracy': accuracy,
86         'f1_macro': f1_macro,
87         'f1_weighted': f1_weighted,
88         'confusion_matrix': cm,
89         'depression_precision': precision,
90         'depression_recall': recall,
91         'depression_f1': f1,
92         'false_negatives': false_negatives,
93         'true_positives': true_positives,
94         'total_depression': total_depression,
95     }
96

```

## 데이터 입력

```

1  phq9_total_result=[]
2
3
4
5  results={'task':'six_label_all_text_phq9',
6          'text': 'all',
7          'label':'six',
8          'model':'finetuning',
9          }

```

```

1  batch_size=8
2  epoch=6

```

```

1  six_label_depression_classes = [3, 4, 5]
2  four_label_depression_classes = [1]

```

```

1  train_loader, test_loader, label_count=FineTuning_data_load(data_phq9, max_length)

```

```

클래스 수: 6
0: 기쁨
1: 당황
2: 분노
3: 불안
4: 상처
5: 슬픔

```

▲ 메모리 절약용 '우물' `WeightedRandomSampler` (실시간 밸런싱)를 사용합니다.  
📈 훈련 데이터: 2013개  
✅ 테스트 데이터: 863개

```
1 device = torch.device('cuda' if torch.cuda.is_available() else 'cpu')
2 finetuning_model = klueClassifier(num_class=label_count, num_layers_to_train=3, dropout=0.3).to(device)
3
4
5 FineTuning_criterion=nn.CrossEntropyLoss()
6 finetuning_optimizer = torch.optim.AdamW([
7     {'params': finetuning_model.klue.parameters(), 'lr': 2e-5},      # KLUE는 작게
8     {'params': finetuning_model.classifier.parameters(), 'lr': 1e-4} # 분류기는 크게
9 ], weight_decay=0.01)
```

Some weights of RobertaModel were not initialized from the model checkpoint at klue/roberta-base and are newly initialized: ['pooler.dense.bias', 'pooler.dense.weight']  
You should probably TRAIN this model on a down-stream task to be able to use it for predictions and inference.

```
1 FineTuning_train(train_loader, finetuning_model, FineTuning_criterion, FineTuning_optimizer, device, epochs=6)

100%|#####| 252/252 [01:34:00:00, 2.68it/s]
Epoch 0: Loss=1.490563045315208
100%|#####| 252/252 [01:33:00:00, 2.69it/s]
100%|#####| 252/252 [01:33:00:00, 2.69it/s]
Epoch 2: Loss=0.5967151057270784
100%|#####| 252/252 [01:33:00:00, 2.69it/s]
100%|#####| 252/252 [01:33:00:00, 2.69it/s]
Epoch 4: Loss=0.35238303196808646
100%|#####| 252/252 [01:33:00:00, 2.69it/s]

{'Epoch': [0, 1, 2, 3, 4, 5],
 'loss': [1.490563045315208,
          0.7804750747505634,
          0.5967151057270784,
          0.42897720485630014,
          0.35238303196808646,
          0.30347258505632315]}

1 torch.save(finetuning_model.state_dict(), SAVE_PATH + 'phase3_six_label_all_text_phq9.pt')
2 print("모델 저장 완료")
```

모델 저장 완료

```
1 six_label_depression_classes = [3, 4, 5]
2 four_label_depression_classes = [1]
```

```
1 result=FineTuning_eval(test_loader, finetuning_model, six_label_depression_classes, device=device)
```

✅ Accuracy: 0.7115  
✅ Macro F1-Score: 0.5136  
✅ Weighted F1-Score: 0.7115

📊 Confusion Matrix:

[[145	6	1	3	0	13]
[12	8	1	0	0	6]
[5	1	11	0	1	10]
[9	1	2	142	1	43]
[1	1	0	1	1	3]
[24	12	13	78	1	307]]

=====

🧠 우물 신호 집중 분석 ([3, 4, 5])

=====

🧠 우물 신호 집중 분석 (불안 + 상처 + 슬픔)

✅ Precision: 0.9459  
✅ Recall: 0.9016  
✅ F1-Score: 0.9232

⚠️ False Negative: 63건 / 640건  
✅ True Positive: 577건 / 640건

```
1 results.update(result)
```

```
1 total_result.append(results)
```

```
1 total_result

[[{'task': 'six_label_all_text_phq9_multimodal',
  'text': 'all',
  'label': 'six',
  'model': 'multimodal',
  'accuracy': 0.6465816917728953,
  'f1_macro': 0.473413940069802,
  'f1_weighted': 0.6442434842235258,
  'confusion_matrix': array([[158, 2, 4, 1, 0, 3],
                             [14, 6, 2, 2, 0, 3],
                             [4, 4, 15, 3, 0, 2],
                             [12, 1, 2, 162, 0, 21],
                             [1, 1, 1, 1, 1, 2],
                             [42, 15, 36, 124, 2, 216]]),
  'depression_precision': 0.9742173112338858,
  'depression_recall': 0.826525,
  'depression_f1': 0.8943364327979713,
  'false_negatives': np.int64(111),
  'true_positives': np.int64(529),
  'total_depression': np.int64(640)},
 {'task': 'six_label_all_text_phq9',
  'text': 'all',
  'label': 'six',
  'model': 'finetuning',
  'accuracy': 0.7114716106904867,
  'f1_macro': 0.5136014461465877,
  'f1_weighted': 0.711471490548801,
  'confusion_matrix': array([[145, 6, 1, 3, 0, 13],
                             [12, 8, 1, 0, 0, 6],
                             [5, 1, 11, 0, 1, 10],
                             [9, 1, 2, 142, 1, 43],
                             [1, 1, 0, 1, 1, 3],
                             [24, 12, 13, 78, 1, 307]]),
  'depression_precision': 0.9459016393442623,
  'depression_recall': 0.9015625,
  'depression_f1': 0.9232,
  'false_negatives': np.int64(63),
  'true_positives': np.int64(577),
  'total_depression': np.int64(640)}]]
```



```
1 import gc
2 del finetuning_model
3 del FineTuning_optimizer
4 torch.cuda.empty_cache()
5 gc.collect()

4763
```

## ❏ 비교 및 시각화

```
1 total_result=pd.DataFrame(total_result)
```

```
1 total_result.to_csv('total_result_phase3')
```

1 total_result															
	task	text	label	model	accuracy	f1_macro	f1_weighted	confusion_matrix	depression_precision	depression_recall	depression_f1	false_negatives	true_positives	total_depression	
0	six_label_all_text_phq9_multimodal	all	six	multimodal	0.646582	0.473414	0.644243	[[158, 2, 4, 1, 0, 3], [14, 6, 2, 2, 0, 3], [4...	0.974217	0.826562	0.894336	111	529	640	
1	six_label_all_text_phq9	all	six	finetuning	0.711472	0.513601	0.711471	[[145, 6, 1, 3, 0, 13], [12, 8, 1, 0, 0, 6], [...	0.945902	0.901563	0.923200	63	577	640	

다음 단계:

[total\\_result 변수로 코드 생성](#)

[New interactive sheet](#)






```
1 import matplotlib.pyplot as plt
2 import seaborn as sns
```

```
1 f1_macro = six_label_all_text_phq9_multimodal['f1_macro'].mean()
```

```

1 figure, axs = plt.subplots(5, 1, figsize=(10, 20))
2
3 metrics=['accuracy', 'f1_macro', 'depression_precision', 'depression_recall', 'depression_f1']
4
5 for i, v in enumerate(metrics):
6     #axs[i].bar(total_result['task'], total_result[v])
7     sns.barplot(data=total_result, x='task', y=v, hue='model', ax= axs[i])
8     axs[i].set_title(v, fontsize=18)
9     axs[i].set_ylabel('Score')
10    axs[i].grid(axis='y', alpha=0.3)
11    axs[i].set_ylim(bottom=total_result[v].min() * 0.99)
12
13 plt.tight_layout(h_pad=5.0)
14
15 plt.show()

```



1 코딩을 시작하거나 시료 코드를 생성하세요.