

청소년 우울 신호 탐지 시스템

텍스트와 음성데이터를 결합한 **멀티모달 딥러닝** 기반
청소년 우울 신호 조기 탐지 시스템 개발

프로젝트 기간 2025.10 - 2025.11

데이터 AI Hub 감성 대화 말뭉치 (10,582건),
음성 데이터 (2,876건)

실험 구성 3 Phases, 14개 체계적 비교 실험

핵심 기술 스택

PyTorch

Transformers

scikit-learn

KLUE-RoBERTa

FastAPI

Docker

Streamlit

AWS

해결하려는 문제

기존 감성분석 시스템의 한계와 개선필요성, 우울 위험 신호 조기 탐지

⚠️ 핵심 문제 상황

기존 감성 분석 모델은 6개 감정(기쁨, 당황, 분노, 불안, 상처, 슬픔)을 동등하게 분류하지만, 임상 심리학 관점에서는 일부 감정이 우울증의 핵심 신호입니다. 특히 청소년 상담 현장에서는 "짜증"과 "좌절감", "화남"과 "무력감"을 구분하여 실제 위험이 있는 청소년을 조기에 발견하는 것이 중요합니다.

× 기존 접근법의 한계

- 단순 6개 감정 분류: 모든 감정을 동등하게 취급
- 문맥 무시: 단일 문장만 분석하여 대화 흐름 파악 실패
- 도메인 지식 부재: 임상 심리학적 진단 기준 미반영
- 단일 모달리티: 텍스트만 분석하여 음성의 비언어적 신호 누락

✓ 본 프로젝트의 접근법

- ✓ 우울 신호 그룹화: 불안/상처/슬픔을 "우울 신호"로 재분류
- ✓ 전체 문맥 활용: 3턴 대화 전체를 입력으로 사용
- ✓ PHQ-9 통합: 우울증 선별검사 기준을 특징으로 추가
- ✓ 멀티모달 융합: 텍스트 의미 + 음성 운율 결합

□ 프로젝트 목표: 우울 신호 탐지율(Recall)을 극대화하여 False Negative를 최소화하고, 실제 위험군을 놓치지 않는 시스템 구축

체계적인 3단계 접근법

점진적 성능 개선을 위한 단계별 비교 실험 설계

01

Phase 1

라벨링 & 문맥 비교

- 8개 모델 비교 실험
- 6-class vs 4-class 라벨
- 전체 문맥 vs 첫 문장
- MLP vs Fine-tuning

최종 선정

6-class + 전체 문맥
+ Fine-tuning

02

Phase 2

PHQ-9 효과 검증

- 4개 모델 비교 실험
- PHQ-9 있음 vs 없음
- 의미 유사도 특징 추출
- 우울증 진단 기준 반영

핵심 발견

PHQ-9 추가로
Recall +1.17%p

03

Phase 3

멀티모달 융합

- 2개 모델 비교 실험
- 텍스트 단독 vs 멀티모달
- MFCC 음성 특징 추출
- Late Fusion 전략

실험 결과

성능 하락 → 원인
분석

실험 설계 철학

✓ 체계적 비교 (Ablation Study)

각 Phase마다 단 하나의 변수만 변경하여 그 효과를 명확히 측정했습니다. (예: Phase 2에서는 PHQ-9 추가 외 다른 조건 고정)

✓ 재현 가능성 보장

모든 실험에서 Random Seed(42) 고정, Train/Test 비율(80:20) 유지, 동일한 전처리 파이프라인을 적용했습니다.

총 14개 실험 구성: Phase 1 (8개) + Phase 2 (4개) + Phase 3 (2개) = 체계적인 성능 개선 과정 검증

텍스트 데이터 파이프라인

Phase 1 & Phase 2 공통 및 PHQ-9 전처리 과정

10,582 Samples

Data Collection

- 감성대화 말뭉치
(AI Hub 데이터셋)
- 청소년 감정 대화 필터링
- 감정 분류: 6개 대분류
(기쁨, 슬픔, 분노, 불안, 상처, 당황)

Preprocessing

- 텍스트 정제:
Regex 특수문자 제거
- 라벨 재정의:
6 Class → 4 Class
(우울신호, 일반부정, 긍정, 중립)
- Train/Test Split (7:3)

Phase 2 Key
Feature Engineering

- PHQ-9 기반 가중치:
KLUE 토크나이저 후
임상 키워드 유사도 계산
- 코사인 유사도:
문장-증상 키워드 매칭
- 문맥 분리: 전체/첫문장

Tokenization

- Tokenizer:
KLUE/RoBERTa-base
- Max Length:
90% Percentile 기준
(all: 71 / first: 28)
- Padding / Truncation

Model & Output

- Base Model:
KLUE/RoBERTa Fine-tuning
- 비교 모델:MLP vs Fine-Tuning
- Output:
우울 위험도 분류
(6-class / 4-class)

입력 데이터

출력 결과

input_ids

attention_mask

phq9_features

우울 위험도 점수

감정 분류 결과

Phase 1: 라벨링 & 문맥 비교

8개 모델 비교를 통한 최적 입력 전략 도출

실험 결과 (상위 4개 모델)



핵심 발견

- 1. 6-class 우수: "짜증" vs "좌절감" 같은 미묘한 차이가 중요 단서.
- 2. 전체 문맥 필수: 대화 흐름 파악으로 첫 문장 대비 Recall 1.17%p 상승.
- 3. Fine-tuning 압도적: MLP 방식(48.45%) 대비 33.84%p 높은 성능 기록.

우울 신호 그룹 정의

우울 신호 (3개 감정)

불안, 상처, 슬픔

비우울 신호 (3개 감정)

기쁨, 당황, 분노

데이터 분포 (총 10,582건)

불안(1998), 슬픔(1887), 상처(1818), 당황(1844), 분노(1792), 기쁨(1243)
→ **우울 신호: 53.9% (5,703건)**

Phase 1 결론
6-class + 전체 문맥 + Fine-tuning 조합이 우울 신호 탐지에 가장 효과적이므로, 이를 Phase 2의 Baseline으로 선정했습니다.

Phase 2: PHQ-9 도메인 지식 주입

우울증 임상 진단 기준을 모델에 반영한 효과 검증

□ PHQ-9란?

DSM-5의 주요 우울증 진단 기준 9가지를 반영한 자가보고식 선별 검사지입니다. (항목: 기분 저하, 흥미 상실, 수면, 식욕, 자살/자해 생각 등)

방법론: 의미 유사도 기반 특징 추출

PHQ-9 키워드 벡터와 입력 텍스트 벡터 간의 코사인 유사도를 계산하여 모델의 추가 특징으로 사용했습니다.

```
similarity = cosine_similarity(text_emb, phq9_emb)

# 3단계 가중치 적용
Direct Core (x3.0):   자살자해직접 표현
Core List (x2.0):     우울무기력집중력 저하
Indirect List (x1.0): 수면식욕 변화
```

중요한 실험적 발견

키워드 매칭은 오히려 노이즈가 되었습니다. 최종적으로 '유사도'만 사용한 모델이 더 높은 성능을 보여 도메인 지식의 '맥락적' 적용이 중요함을 확인했습니다.

실험 결과 비교

6-class + PHQ-9 False Negative 283건 (16.5%) → Baseline 대비 FN 20건 감소 (6.6% 개선)	제안 모델 Recall 83.46%
Baseline (PHQ-9 없음) False Negative 303건 (17.7%)	Recall 82.29%

핵심 인사이트

- 1. 도메인 지식 효과:임상 심리학 진단 기준 주입으로 유의미한 성능 향상.
- 2. 고효율:추가 데이터 학습 없이 유사도 특징(1차원)만으로 우울 신호 20건 추가 탐지.
- 3. 자살/자해 탐지:임상적으로 중요한 고위험 표현 탐지 강화에 기여.



Phase 2 결론

6개 감정 분류 전체 대화 맥락 데이터 + PHQ-9 + Fine-tuning을 baseline 모델로 설정하여, Phase 3에서 음성 특징을 추가한 멀티모달 모델과 비교

음성 데이터 파이프라인


Phase 3 멀티모달 음성 전처리 과정

2,876 Audio Files



Phase 3: 멀티모달 융합 실험

텍스트와 음성 데이터 결합 시도 및 성능 하락 원인 분석



실패에서 배운 점

멀티모달이 항상 정답은 아님을 배웠습니다. 모달리티 간 성능 불균형이 발생할 수 있으며, 특히 각 데이터마다 전처리 및 특성 공학 난이도가 다를 수 있습니다. 각 모달리티의 개별 성능 뒷받침이 필수적입니다.

실험 결과

✓ 텍스트 단독 (Best) Recall 90.16%

× 멀티모달 융합 Recall 82.66%

▼ 성능 하락: Recall -7.5%p, False Negative +48건 증가

성능 하락 원인 분석

1. 모달리티 간 성능 불균형 (핵심 원인)

텍스트모델(사전학습+Fine-tuning)은 고성능이나, 음성 모델(LSTM)은 상대적 저성능입니다. 융합 시 저성능 음성 모델이 텍스트 모델의 판단력을 희석시켰습니다.

2. 컴퓨팅 리소스 제약

Colab 무료 버전 한계로 Wav2Vec 2.0 같은 고성능 음성 모델 실험이 불가능했습니다.

3. 음성 데이터 품질 문제

연기된 데이터셋 특성상 실제 우울 환자의 미묘한 운율적 특징(Tone, Pitch 등)이 부족했습니다.

Phase 3 결론

현재는 텍스트 단독 모델(71.15%)이 우세하나, 운율·톤·발화 속도 등 음성의 비언어적 정보 활용을 위해 **멀티모달 모델을 배포**했습니다. 음성 특징 추출 기법 개선 시 성능 향상 가능성이 높습니다.

배포 로드맵

실제 서비스구현을 위한 단계별 실행 계획

1



API 개발

- FastAPI 서버 구축
- Predict 엔드포인트 구현
- 텍스트 전처리 파이프라인
- 모델 추론 로직 통합

2



컨테이너화

- Dockerfile 작성
- Docker Image 빌드 (requirements.txt 포함)
- 로컬 환경 테스트

3



Streamlit

- 웹 인터페이스 개발
- 사용자 입력 폼 구현
- 분석 결과 시각화
- API 연동 테스트

4



클라우드 배포


- AWS EC2 인스턴스 설정
- S3 모델 저장소 연동
- Docker 컨테이너 배포
- 외부 접속 허용

서비스 배포 및 데모


배포 플랫폼: AWS EC2 + Streamlit

배포 URL: <http://43.201.10.85:8501>


1. 서비스 메인 화면




2. 파일 업로드 화면



3. 분석 결과



4. 감정 분포 차트



프로젝트 성과 및 향후 계획

실험을 통해 얻은 최종 성과와 인사이트

★ 핵심 교훈

- 1. 모달리티 균형
각 모달리티가 비슷한 수준의 성능을 가져야 시너지가 납니다.
- 2. 사전학습 모델의 중요성
음성에서도 Wav2Vec 같은 사전학습 모델 도입이 성능 확보에 필수적입니다.
- 3. 리소스 확보
멀티모달은 단일 모델보다 훨씬 많은 GPU 자원을 요구하므로 환경 구축이 선행되어야 합니다.

→ 향후 개선 방향

- ✓ 음성 사전학습 모델 도입 (HuBERT 등)
- ✓ Late Fusion 대신 Cross-modal Attention 적용
- ✓ Colab Pro 또는 클라우드 GPU 환경 확보
- ✓ 실제 상담 음성 데이터 확보 (Quality 개선)

실무 적용 가능성

학교/청소년 상담센터의 초기 선별 도구로 활용 가능.
위험 신호를 놓치지 않는 보조 도구(Assistant) 역할 수행.

주요 학습 포인트

- 1. 체계적 실험: 단계적으로 모델의 성능을 확인하며 개선 근거 확보
- 2. 도메인 지식: PHQ-9 통합으로 적은 비용, 큰 효과 입증
- 3. 실패 학습: 멀티모달 한계 분석을 통한 인사이트 도출

개발 환경

Environment

Google Colab (GPU)

Framework

PyTorch 2.0

NLP Model

klue/roberta-base

Audio Lib

Librosa 0.10.0

Contact & Code

- ✉ xogur1578@gmail.com
- 📁 github.com/TaehyukRyu/depression-detection